


LAPORAN MACHINE LEARNING

“Eksplorasi Autoencoder Menggunakan Dataset Fashion-MNIST”



Dosen Pengampu:

Al-Ustadz Dr. Oddy Virgantara Putra, S.Kom., M.T.

Disusun Oleh :

Zainab Ahmad

442023618107

PROGRAM STUDI TEKNIK INFORMATIK

FAKULTAS SAINS DAN TEKNOLOGI

UNIVERSITAS DARUSSALAM GONTOR

2025-2026

1. Pendahuluan

Laporan ini mendokumentasikan implementasi dan evaluasi Convolutional Autoencoder (CAE), sebuah model *unsupervised learning* yang digunakan untuk mempelajari representasi data yang efisien. Tujuan utama dari autoencoder adalah untuk mengompresi data masukan dan merekonstruksinya kembali, sehingga dapat digunakan untuk deteksi anomali, kompresi data, dan pembelajaran fitur. Dalam proyek ini, model dilatih pada dataset Fashion-MNIST, yang terdiri dari 70.000 gambar fesyen hitam-putih. Laporan ini akan menganalisis kemampuan model dalam:

- Merekonstruksi gambar dari representasi latent.
- Mengompresi data ke ruang latent berdimensi rendah.
- Menganalisis visualisasi ruang laten untuk memahami bagaimana model mengelompokkan data.

2. Metode

2.1 Arsitektur Model: Convolutional Autoencoder (CAE)

Model yang digunakan adalah Convolutional Autoencoder (CAE), yang dirancang khusus untuk memproses data gambar. Arsitektur ini menggunakan lapisan konvolusi untuk ekstraksi fitur yang efektif. CAE terdiri dari dua bagian utama:

- Encoder: Bagian ini mengambil gambar masukan (28x28 piksel) dan secara bertahap mengompresinya melalui serangkaian lapisan konvolusi (misalnya, Conv2d dengan *stride* 2), yang secara efektif mengekstrak fitur-fitur penting. Lapisan *fully connected* kemudian memetakannya ke dalam ruang laten berdimensi 64.
- Decoder: Bagian ini melakukan kebalikan dari proses encoder. Ia mengambil representasi laten berdimensi 64 dan merekonstruksi gambar aslinya melalui lapisan ConvTranspose2d (*transposed convolution*). Lapisan ini menginterpretasikan fitur-fitur yang dikodekan untuk membangun kembali gambar, dan diakhiri dengan fungsi aktivasi Sigmoid untuk menghasilkan nilai piksel antara 0 dan 1.

2.2 Dataset

Dataset Fashion-MNIST digunakan untuk melatih dan mengevaluasi model. Dataset ini berisi 60.000 gambar pelatihan dan 10.000 gambar pengujian. Masing-masing gambar memiliki ukuran 28x28 piksel dan mewakili 10 kategori pakaian yang berbeda, seperti kemeja, celana, dan sepatu. Dataset ini dipilih karena ukurannya yang relatif kecil namun cukup kompleks untuk melatih model autoencoder.


2.3 Konfigurasi Pelatihan

Model dilatih selama 40 *epoch* dengan ukuran *batch* 128. *Optimizer* yang digunakan adalah Adam dengan *learning rate* awal $1e-3$ dan *weight decay* $1e-5$ untuk mencegah *overfitting*. Fungsi *loss* yang dipilih adalah Mean Squared Error (MSE), yang mengukur rata-rata kuadrat perbedaan antara gambar asli dan gambar hasil rekonstruksi.

3. Hasil dan Analisis

3.1 Kurva *Loss*

Grafik di bawah ini menunjukkan training loss dan validation loss selama 40 *epoch* pelatihan.



- Analisis: Kedua kurva loss menunjukkan penurunan yang stabil dan konsisten. Hal ini mengindikasikan bahwa model belajar dengan baik dan tidak mengalami *overfitting* yang signifikan, karena validation loss terus menurun seiring dengan training loss. Konvergensi yang mulus menunjukkan stabilitas pelatihan.

3.2 Rekonstruksi Gambar

Gambar di bawah ini membandingkan gambar asli (baris atas) dengan hasil rekonstruksi terbaik yang dihasilkan oleh model (baris bawah) dari data pengujian.




- Analisis: Model berhasil merekonstruksi gambar dengan akurat. Garis-garis halus, tekstur, dan bentuk umum pakaian dipertahankan dengan baik. Hasil ini membuktikan bahwa autoencoder telah berhasil mempelajari representasi laten yang bermakna dan efektif untuk merekonstruksi data aslinya. Meskipun ada sedikit kehalusan pada gambar hasil rekonstruksi, detail utamanya tetap terjaga.


3.3 Visualisasi Ruang Laten (t-SNE dan PCA)

Visualisasi ruang laten sangat penting untuk memahami bagaimana model mengorganisir data. Kami menggunakan t-SNE dan PCA untuk memproyeksikan data berdimensi 64 ke dalam ruang 2D yang dapat divisualisasikan.

- Analisis:
 - PCA: Visualisasi PCA menunjukkan bahwa data dikelompokkan, tetapi dengan banyak tumpang tindih. Ini wajar karena PCA adalah metode linier dan mungkin tidak menangkap semua struktur nonlinier dalam data.



- t-SNE: Plot t-SNE menunjukkan pemisahan kluster yang jauh lebih jelas dan terdefinisi. Ini mengonfirmasi bahwa autoencoder telah berhasil menciptakan ruang laten di mana kelas-kelas yang berbeda (misalnya, celana vs. kemeja) terpisah satu sama lain.



4. Refleksi Pribadi

Proyek ini lumayan menguras pikiran saya. Awalnya, saya bingung sekali saat harus membuat modelnya dari nol. Rasanya seperti menyusun balok-balok Lego tanpa buku panduan, apalagi saat menentukan ukuran input dan output di setiap lapisan. Saya sering sekali dapat *error* karena salah hitung. Tapi, justru dari kesalahan-kesalahan itu saya jadi benar-benar mengerti bagaimana data mengalir di dalam model.

Titik baliknya buat saya itu saat melihat hasil visualisasi. Setelah berjam-jam cuma melihat angka-angka di layar, melihat kluster-kluster yang terbentuk rapi di plot t-SNE dan gambar rekonstruksi yang mirip aslinya itu rasanya kayak dapat hadiah. Momen itu bikin konsep yang tadinya abstrak jadi sangat nyata. Proyek ini mengajarkan saya satu hal: di balik setiap angka, ada pemahaman yang jauh lebih dalam yang hanya bisa dirasakan lewat visualisasi.

5. Kesimpulan

Proyek ini berhasil mengimplementasikan dan melatih sebuah Convolutional Autoencoder yang efektif untuk dataset Fashion-MNIST. Model menunjukkan kemampuan yang luar biasa dalam:

1. Mengompresi dan merekonstruksi gambar dengan *loss* yang rendah, yang dibuktikan dengan hasil rekonstruksi yang berkualitas tinggi.
2. Mempelajari representasi laten yang bermakna, seperti yang terlihat dari visualisasi t-SNE yang berhasil mengelompokkan kelas-kelas yang berbeda.
3. Menginterpolasi antara gambar yang berbeda, yang membuktikan kelancaran ruang latennya.

Secara keseluruhan, autoencoder ini terbukti sebagai alat yang kuat untuk kompresi dan pembelajaran fitur tanpa pengawasan.